Iyed MEDIOUNI



INGÉNIEUR IA · SYSTÈMES LLM & MACHINE LEARNING APPLIQUÉ

Lac 1, Tunis, Tunisie | +216 29 514 155 | iyedmediouni122@gmail.com
linkedin.com/in/iyed-mediouni-673955219 | iyed122.github.io

PROFIL

Ingénieur IA. Je mène les systèmes à base de modèles de langage jusqu'en production : des assistants qui répondent à partir des outils internes de l'entreprise, et la boucle d'évaluation qui prouve qu'une version est meilleure avant sa mise en ligne. L'assistant développé lors de mon stage a été vendu à un client. À l'aise sur toute la chaîne : recherche documentaire, orchestration multi-agents, inférence locale, services FastAPI et console de pilotage.

EXPÉRIENCE PROFESSIONNELLE

02/2026 - 07/2026
Lac 1, Tunis
Projet de fin d'études

Ingénieur IA - TELNET Holding · Assistant IA avec fine-tuning

- L'information projet était éclatée entre trois systèmes tiers : livré un assistant d'entreprise qui interroge Jira, Confluence et GitLab via leurs API et restitue les réponses en langage naturel depuis une interface unique, sur une architecture LangGraph et Neo4j Graph-RAG. TELNET a vendu le produit à un client.
- Passage à l'échelle du corpus client : 1,28 million de segments vectorisés en embeddings 768 dimensions (index vectoriel HNSW quantifié en int8 pour tenir sur une seule carte 6 Go) couvrant 428 593 tickets et 47 851 pages, reliés par plus de 1,8 million de relations typées - recherche hybride vectorielle et parcours de graphe multi-sauts.
- Temps de réponse divisé par 2,4 (7,3 s à 3,0 s) grâce à un routage déterministe des requêtes et à des appels d'API exécutés en parallèle.
- Conception de Hammer, framework d'évaluation (RAGAS + validation déterministe) notant chaque réponse sur deux axes ; son veto déterministe écarte de l'entraînement les fabrications détectées - 62 exclues d'un pool de 138 documents.
- Fine-tuning RAFT de Qwen3-8B (QLoRA 4-bit) sur les verdicts de Hammer : ancrage dans une citation vérifiable porté de 0 à 95,8 % et refus ramenés de 19,0 % à 7,6 %. Adaptateur promu en production par une porte statistique fixée avant l'entraînement : 2,1 écarts-types sur 366 questions de test, ancrage maintenu à 94,8 %.
- Système livré prêt à l'exploitation : services FastAPI conteneurisés avec Docker, persistance MongoDB, inférence locale via Ollama, suivi des entraînements sous MLflow et console React/Vite pour le pilotage - la boucle d'évaluation assurant aussi le suivi en production (qualité, latence, échecs).

PROJETS

09/2025 - 11/2025

Pipeline d'automatisation multi-agents · github.com/iyed122/automated-twitter-content

- Un contenu générique décroche vite de ce qui intéresse vraiment : pipeline d'agents autonomes (CrewAI + LLaMA-3-70B, Groq) qui collecte des données depuis plusieurs sources en ligne, les recoupe, puis produit un contenu adossé à ses sources.
- Intégration complète d'une API tierce avec authentification OAuth sécurisée, de la collecte jusqu'à la publication automatisée.

07/2025 - 10/2025

Véhicule autonome : perception et revue des risques de conduite · github.com/iyed122/autonomous-vehicule-VLM

- Une flotte enregistre plus de conduite qu'on ne peut en regarder : file de revue sur des données LiDAR réelles (nuScenes) - vitesse mesurée par recalage des scans, couche de risque NumPy (CLEAR / CAUTION / BRAKE) - seuls 9 moments (2 % de 28 min) restent à voir.
- Planificateur de trajectoire PyTorch vue-du-dessus et YOLOv8 entraînés sur AWS SageMaker (200 Go) ; planificateur évalué face au mouvement réel, erreur latérale tracée jusqu'à un bug d'augmentation.
- Modèle de langage local (Ollama) : une note par moment signalé ; tableau de bord Streamlit, rapports PDF, alertes vocales.

02/2023 - 06/2023
Ghazela, Technopole
Projet de fin d'études

Développeur Full-Stack & IA - AURAX · Développement site e-commerce avec IA

- Un catalogue seul ne convertit pas : parcours client complet en MERN (React, Node.js, Express, MongoDB) - recherche et filtres, panier, paiement en ligne sécurisé via Stripe, codes promotionnels, suivi et historique des commandes.
- Moteur de recommandation visuelle (VGG16, PCA, KNN) entraîné sur plus de 50 000 images produits, exposé via une API Flask et opérationnel dès la première visite, sans historique.
- Autonomie donnée aux équipes métier : back-office de gestion du catalogue, des tarifs, des promotions et des stocks avec tableau de bord chiffre d'affaires, mené en entreprise (GitLab, Linear).

FORMATION

2023 - 2026
Diplôme d'ingénieur - Data Science & Intelligence Artificielle
TEK-UP University

2020 - 2023
Licence en Informatique
ISAMM, Manouba

COMPÉTENCES TECHNIQUES

IA & ML	LLM · LangGraph · LangChain · CrewAI · RAG & Graph-RAG · embeddings · RAGAS · Fine-tuning RAFT · Ollama · PyTorch · TensorFlow · Scikit-learn · OpenCV
LANGAGES	Python · JavaScript · SQL · PL/SQL · R · MATLAB
DONNÉES & BACKEND	Neo4j · Qdrant (base vectorielle) · MongoDB · PostgreSQL · MySQL · Cassandra · FastAPI · API REST · Pandas · NumPy · Power BI
CLOUD & MLOPS	AWS SageMaker · EC2 · Lambda · S3 · DynamoDB · Redshift · RDS · Docker · MLflow
FRONTEND & OUTILS	React · Vite · Node.js / Express · Streamlit · Git / GitLab · LaTeX

LANGUES & CERTIFICATIONS

ARABE	Langue maternelle
FRANÇAIS	Courant - rédaction professionnelle et technique
ANGLAIS	IELTS Academic, British Council - B2 (6,5 / 9)