

Iyed MEDIOUNI

INGÉNIEUR IA · SYSTÈMES LLM & MACHINE LEARNING APPLIQUÉ

Lac 1, Tunis, Tunisie +216 29 514 155 iyedmediouni122@gmail.com
linkedin.com/in/iyed-mediouni-673955219 iyed122.github.io



PROFIL

Ingénieur IA. Je mène les systèmes à base de modèles de langage jusqu'en production : des assistants qui répondent à partir des outils internes de l'entreprise, et la boucle d'évaluation qui prouve qu'une version est meilleure avant sa mise en ligne. L'assistant développé lors de mon stage a été vendu à un client. À l'aise sur toute la chaîne : recherche documentaire, orchestration multi-agents, inférence locale, services FastAPI et console de pilotage.

EXPÉRIENCE PROFESSIONNELLE

02/2026 - 07/2026 Lac 1, Tunis Projet de fin d'études	Ingénieur IA - TELNET Holding · Assistant IA avec fine-tuning ● github.com/iyed122/ai-assistant - L'information projet était éclatée entre trois systèmes tiers : livré un assistant d'entreprise qui interroge Jira, Confluence et GitLab via leurs API et restitue les réponses en langage naturel depuis une interface unique, sur une architecture LangGraph et Neo4j Graph-RAG. TELNET a vendu le produit à un client. - Passage à l'échelle du corpus client : 1,28 million de segments vectorisés en embeddings 768 dimensions (index vectoriel HNSW quantifié en int8 pour tenir sur une seule carte 6 Go) couvrant 428 593 tickets et 47 851 pages, reliés par plus de 1,8 million de relations typées - recherche hybride vectorielle et parcours de graphe multi-sauts. - Temps de réponse divisé par 2,4 (7,3 s à 3,0 s) grâce à un routage déterministe des requêtes et à des appels d'API exécutés en parallèle. - Le fine-tuning avançait sans mesure de qualité : conception de Hammer, framework d'évaluation (RAGAS + validation déterministe) notant chaque réponse sur deux axes. Il a révélé un défaut de notation qui laissait 62 réponses fabriquées dans le jeu d'entraînement - pool positif assaini de 138 à 54 documents. - Fine-tuning RAFT (QLoRA 4-bit) sur les verdicts de Hammer : ancrage des réponses dans une citation vérifiable porté de 0 à 95,8 % et refus ramenés de 19,0 % à 7,6 %. Mise en place d'une porte de promotion à seuils statistiques fixés avant l'entraînement - aucun adaptateur ne rejoint la production sans gain démontré sur un jeu de test réservé. - Système livré prêt à l'exploitation : services FastAPI conteneurisés avec Docker, persistance MongoDB, inférence locale via Ollama, suivi des entraînements sous MLflow et console React/Vite pour le pilotage - la boucle d'évaluation assurant aussi le suivi en production (qualité, latence, échecs).
---	--

PROJETS

09/2025 - 11/2025	Pipeline d'automatisation multi-agents ● github.com/iyed122/automated-twitter-content - Un contenu générique décroche vite de ce qui intéresse vraiment : pipeline d'agents autonomes (CrewAI + LLaMA-3.1-8B) qui collecte des données depuis plusieurs sources en ligne, les recoupe, puis produit un contenu adossé à ses sources. - Intégration complète d'une API tierce avec authentification OAuth sécurisée, de la collecte jusqu'à la publication automatisée.
07/2025 - 10/2025	Perception et prédiction de trajectoires pour véhicule autonome ● github.com/iyed122/autonomous-vehicule-VLM - La détection seule ne dit pas où va un objet : pipeline de bout en bout sur AWS SageMaker associant un détecteur YOLOv8 affiné à un modèle vue-du-dessus pour la prédiction de trajectoires LiDAR, entraîné sous PyTorch (ADE 0,8 / FDE 1,2). - Tableau de bord Streamlit rendant le résultat lisible pour des non-spécialistes : détection en direct, trajectoires et signal de risque CLEAR / CAUTION / BRAKE sur 6 caméras et LiDAR. - Boucle refermée vers le conducteur : un modèle vision-langage local (Qwen2.5-VL) lit l'ensemble des capteurs et une synthèse vocale énonce la consigne à voix haute - continuer, faire une pause, ou véhicule proche - sans avoir à regarder un écran.
02/2023 - 06/2023 Ghazela, Technopole Projet de fin d'études	Développeur Full-Stack & IA - AURAX · Développement site e-commerce avec IA - Un catalogue seul ne convertit pas : parcours client complet en MERN (React, Node.js, Express, MongoDB) - recherche et filtres, panier, paiement en ligne sécurisé via Stripe, codes promotionnels, suivi et historique des commandes. - Moteur de recommandation visuelle (VGG16, PCA, KNN) entraîné sur plus de 50 000 images produits, exposé via une API Flask et opérationnel dès la première visite, sans historique. - Autonomie donnée aux équipes métier : back-office de gestion du catalogue, des tarifs, des promotions et des stocks avec tableau de bord chiffre d'affaires, mené en entreprise (GitLab, Linear).

FORMATION

2023 - 2026	Diplôme d'ingénieur - Data Science & Intelligence Artificielle TEK-UP University
2020 - 2023	Licence en Informatique ISAMM, Manouba

COMPÉTENCES TECHNIQUES

IA & ML	LangGraph · LangChain · CrewAI · Graph-RAG · RAGAS · Fine-tuning RAFT · Ollama · PyTorch · TensorFlow · Scikit-learn · OpenCV
LANGAGES	Python · JavaScript · SQL · PL/SQL · R · MATLAB
DONNÉES & BACKEND	Neo4j · Qdrant · MongoDB · PostgreSQL · MySQL · Cassandra · FastAPI · Pandas · NumPy
CLOUD & MLOPS	AWS SageMaker · EC2 · Lambda · S3 · DynamoDB · Redshift · RDS · Docker · MLflow
FRONTEND & OUTILS	React · Vite · Node.js · Streamlit · Git / GitLab · LaTeX

LANGUES & CERTIFICATIONS

ARABE	Langue maternelle
FRANÇAIS	Courant - rédaction professionnelle et technique
ANGLAIS	IELTS Academic, British Council - B2 (6,5 / 9)