

Iyed MEDIOUNI

INGÉNIEUR IA · SYSTÈMES LLM & MACHINE LEARNING APPLIQUÉ

Hammamet, Tunisie | +216 29 514 155 | iyedmediouni122@gmail.com
[LinkedIn](https://www.linkedin.com/in/iyed-mediouni) [linkedin.com/in/iyed-mediouni](https://www.linkedin.com/in/iyed-mediouni) | [GitHub](https://github.com/iyed122) github.com/iyed122
Portfolio iyed122.github.io



PROFIL

Ingénieur IA spécialisé dans les systèmes LLM en production, de bout en bout : recherche hybride Graph-RAG sur Neo4j, orchestrateur multi-agents LangGraph avec routage d'API en temps réel, et boucle d'évaluation auto-améliorante qui conditionne le fine-tuning QLoRA/DPO à un gain de qualité mesuré. À l'aise autant sur la modélisation que sur l'infrastructure : inférence on-premise, services FastAPI, conception de la recherche documentaire et outillage opérateur. Réalisations en systèmes multi-agents, pipelines de vision par ordinateur et recherche appliquée en sécurité.

EXPÉRIENCE PROFESSIONNELLE

02/2026 – 06/2026	Ingénieur IA (stage) — TELNET Holding
Lac 1, Tunis	- La connaissance projet était dispersée entre Jira, Confluence et GitLab : livré un assistant d'entreprise on-premise en production, bâti sur LangGraph et Neo4j Graph-RAG, qui répond sur les trois sources depuis une seule interface en langage naturel. - Les premières réponses étaient trop lentes pour un usage interactif : conception d'un routage hybride des requêtes associant classification déterministe et appels d'API parallèles, réduisant la latence moyenne de 2,4x (7,3 s → 3,0 s). - Le fine-tuning avançait à l'aveugle, sans mesure de la qualité des réponses : conception de Hammer, un framework d'évaluation (RAGAS + validation déterministe) qui note chaque réponse sur une échelle à quatre niveaux croisée avec une taxonomie d'échecs, de sorte qu'aucun cycle QLoRA/DPO ne soit lancé sans gain démontré. - Identification d'un défaut de scoring silencieux qui classait des réponses correctes en échecs et dégradait le jeu d'entraînement ; sa correction a amélioré la qualité des données de ~10 points et la fidélité du modèle de 27 %. - Passage du prototype à un système exploitable par une équipe : services d'entraînement FastAPI, persistance MongoDB, inférence locale via Ollama et console React/Vite pour le mode entraînement, la curation DPO et la revue des candidats QLoRA.

PROJETS

07/2025 – 10/2025	Perception et prédiction de trajectoires pour véhicule autonome
	REPO github.com/iyed122/autonomous-vehicule-VLM
	- La détection caméra seule ne permet pas d'anticiper la trajectoire d'un objet : pipeline de bout en bout sur AWS SageMaker associant un détecteur YOLOv8 affiné à un modèle vue-du-dessus dédié à la prédiction de trajectoires LiDAR, entraîné sous PyTorch jusqu'à ADE 0,8 / FDE 1,2. - Résultats rendus lisibles pour des non-spécialistes via un tableau de bord Streamlit : détection en temps réel, visualisation des trajectoires et indicateur de risque de collision (CLEAR / CAUTION / BRAKE) sur 6 caméras et vues LiDAR. - Intégration d'un modèle vision-langage local (Qwen2.5-VL) qui commente les scènes de conduite sur l'ensemble des capteurs, transformant les détections brutes en analyse structurée des dangers.
09/2025 – 11/2025	Automatisation de contenu multi-agents (CrewAI)
	REPO github.com/iyed122/automated-twitter-content
	- Les publications générées par LLM s'éloignent vite des sujets réellement en tendance : pipeline CrewAI + LLaMA-3.1-8B où des agents spécialisés analysent web, recherche et données de tendances avant toute rédaction. - Chaîne bouclée jusqu'à la publication via l'API X avec authentification OAuth sécurisée, et étape d'ancrage reliant chaque publication à ses sources.

FORMATION

2023 – 2026	Diplôme d'ingénieur — Data Science & Intelligence Artificielle TEK-UP University
2020 – 2023	Licence en Informatique ISAMM, Manouba

COMPÉTENCES TECHNIQUES

IA & ML	LangGraph · LangChain · CrewAI · Graph-RAG · RAGAS · Fine-tuning QLoRA / DPO · Ollama · PyTorch · TensorFlow · Scikit-learn · OpenCV
LANGAGES	Python · JavaScript · SQL · PL/SQL · R · MATLAB
DONNÉES & BACKEND	Neo4j · Qdrant · MongoDB · PostgreSQL · MySQL · Cassandra · FastAPI · Pandas · NumPy
CLOUD & MLOPS	AWS SageMaker · EC2 · Lambda · S3 · DynamoDB · Redshift · RDS · Docker · MLflow
FRONTEND & OUTILS	React · Vite · Streamlit · Git / GitLab · LaTeX
SÉCURITÉ	Fondamentaux du test d'intrusion · analyse statique de JavaScript côté client · intégration d'API & OAuth sécurisées

LANGUES & CERTIFICATIONS

ANGLAIS	IELTS Academic, British Council — B2 (6,5 / 9)
FRANÇAIS	Courant — rédaction académique et technique