

Iyed MEDIOUNI

INGÉNIEUR IA · SYSTÈMES LLM & MACHINE LEARNING APPLIQUÉ

Hammamet, Tunisie | +216 29 514 155 | iyedmediouni122@gmail.com
[LinkedIn](https://www.linkedin.com/in/iyed-mediouni) [linkedin.com/in/iyed-mediouni](https://www.linkedin.com/in/iyed-mediouni) | [GitHub](https://github.com/iyed122) github.com/iyed122
Portfolio iyed122.github.io



PROFIL

Ingénieur IA spécialisé dans les systèmes LLM en production, de bout en bout : recherche hybride Graph-RAG sur Neo4j, orchestrateur multi-agents LangGraph avec routage d'API en temps réel, et boucle d'évaluation auto-améliorante qui conditionne le fine-tuning QLoRA/DPO à un gain de qualité mesuré. À l'aise autant sur la modélisation que sur l'infrastructure : inférence on-premise, services FastAPI, conception de la recherche documentaire et outillage opérateur. Réalisations en systèmes multi-agents, pipelines de vision par ordinateur et recherche appliquée en sécurité.

EXPÉRIENCE PROFESSIONNELLE

- 02/2026 - 07/2026
Lac 1, Tunis
- Ingénieur IA (stage) — TELNET Holding
- La connaissance projet était dispersée entre Jira, Confluence et GitLab : livré un assistant d'entreprise on-premise en production, bâti sur **LangGraph** et **Neo4j Graph-RAG**, qui répond sur les trois sources depuis une seule interface en langage naturel.
 - Les premières réponses étaient trop lentes pour un usage interactif : conception d'un routage hybride des requêtes associant classification déterministe et appels d'API parallèles, réduisant la latence moyenne de **2,4x** (7,3 s → 3,0 s).
 - Le fine-tuning avançait à l'aveugle, sans mesure de la qualité des réponses : conception de **Hammer**, un framework d'évaluation (RAGAS + validation déterministe) qui note chaque réponse sur une échelle à quatre niveaux croisée avec une taxonomie d'échecs, de sorte qu'aucun cycle **QLoRA/DPO** ne soit lancé sans gain démontré.
 - Identification d'un défaut de scoring silencieux qui classait des réponses correctes en échecs et dégradait le jeu d'entraînement ; sa correction a amélioré la qualité des données de **~10 points** et la fidélité du modèle de **27 %**.
 - Passage du prototype à un système exploitable par une équipe : services d'entraînement **FastAPI**, persistance MongoDB, inférence locale via **Ollama** et console **React/Vite** pour le mode entraînement, la curation DPO et la revue des candidats QLoRA.

PROJETS

- 07/2025 – 10/2025
- Perception et prédiction de trajectoires pour véhicule autonome
- REPO github.com/iyed122/autonomous-vehicule-VLM
- La détection caméra seule ne permet pas d'anticiper la trajectoire d'un objet : pipeline de bout en bout sur **AWS SageMaker** associant un détecteur **YOLOv8** affiné à un modèle vue-du-dessus dédié à la prédiction de trajectoires LiDAR, entraîné sous PyTorch jusqu'à **ADE 0,8 / FDE 1,2**.
 - Résultats rendus lisibles pour des non-spécialistes via un tableau de bord **Streamlit** : détection en temps réel, visualisation des trajectoires et indicateur de risque de collision (CLEAR / CAUTION / BRAKE) sur 6 caméras et vues LiDAR.
 - Intégration d'un modèle vision-langage local (**Qwen2.5-VL**) qui commente les scènes de conduite sur l'ensemble des capteurs, transformant les détections brutes en analyse structurée des dangers.
- 09/2025 – 11/2025
- Automatisation de contenu multi-agents (CrewAI)
- REPO github.com/iyed122/automated-twitter-content
- Les publications générées par LLM s'éloignent vite des sujets réellement en tendance : pipeline **CrewAI** + **LLaMA-3.1-8B** où des agents spécialisés analysent web, recherche et données de tendances avant toute rédaction.
 - Chaîne bouclée jusqu'à la publication via l'API X avec authentification OAuth sécurisée, et étape d'ancrage reliant chaque publication à ses sources.

FORMATION

- 2023 – 2026
- Diplôme d'ingénieur — Data Science & Intelligence Artificielle
TEK-UP University
- 2020 – 2023
- Licence en Informatique
ISAMM, Manouba

COMPÉTENCES TECHNIQUES

IA & ML	LangGraph · LangChain · CrewAI · Graph-RAG · RAGAS · Fine-tuning QLoRA / DPO · Ollama · PyTorch · TensorFlow · Scikit-learn · OpenCV
LANGAGES	Python · JavaScript · SQL · PL/SQL · R · MATLAB
DONNÉES & BACKEND	Neo4j · Qdrant · MongoDB · PostgreSQL · MySQL · Cassandra · FastAPI · Pandas · NumPy
CLOUD & MLOPS	AWS SageMaker · EC2 · Lambda · S3 · DynamoDB · Redshift · RDS · Docker · MLflow
FRONTEND & OUTILS	React · Vite · Streamlit · Git / GitLab · LaTeX
SÉCURITÉ	Fondamentaux du test d'intrusion · analyse statique de JavaScript côté client · intégration d'API & OAuth sécurisées

LANGUES & CERTIFICATIONS

- ANGLAIS
- IELTS Academic, British Council — B2 (6,5 / 9)
- FRANÇAIS
- Courant — rédaction académique et technique